



# Analisi della Buggyness nei Metodi Software:

Un Approccio Data-Driven al Refactoring


# Indice

- Introduzione
- Misura e Metodologia
- Risultati
- Discussioni e Minacce alla Validità
- Conclusioni e Sviluppi Futuri



# Introduzione

Il problema della manutenibilità



L'incessante integrazione di funzionalità degrada la struttura interna del software. Questo accumulo di **Debito Tecnico** aumenta esponenzialmente la propensione ai difetti nei sistemi complessi.

La letteratura attuale si focalizza su **classi** o **moduli**.  
Manca un'analisi empirica solida a livello di **singolo metodo**.



Studio sui progetti  
**Apache**  
**BookKeeper** e **OpenJPA**  
per validare l'efficacia del  
Machine Learning nella  
predizione dei bug e  
quantificare quanti bug si  
potrebbero prevenire  
attuando mirati  
interventi di **refactoring**.



# Le Domande di Ricerca

**RQ1:** Quale dei classificatori valutati risulta più efficace nell'individuare con precisione i metodi problematici nei due scenari studiati?

**RQ2:** Quanti potenziali bug si sarebbero potuti evitare applicando in tempo attività di refactoring mirate alla rimozione delle anomalie strutturali?



# Misura e Metodologia




# Dataset ed Estrazione delle Etichette

**Target:** Generazione di un dataset etichettato a livello di **metodo**.

buggy

**Input:** Repository **Git** (storico codice) e **Jira** (segnalazioni bug).



**Mitigazione Snoring:** Rimozione selettiva delle release finali per eliminare il rumore.

**Risultato:** Coinvolgimento del **33% delle release** nel dataset finale.



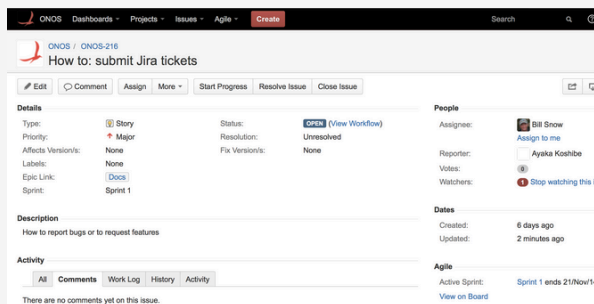
**Associazione Ticket-Commit:** Spesso i messaggi di commit non contengono l'ID del ticket Jira (es. "BOOKKEEPER-123"), portando a una perdita di dati preziosi per il dataset. Quindi si è preferito adottare un approccio ibrido per garantire la qualità del dataset:

```
(venv) gm-conf % git log
commit 1a1712431d11acc040649f99e99cc3f5434cb44b (HEAD -> trunk)
Author: 
Date: Thu Apr 13 10:59:29 2023 +0100

Changes to docs.

commit 275feb54ee8c345933c9d9aba3dc458d7958d535
Author: 
Date: Thu Apr 13 10:48:57 2023 +0100

Initial commit
(venv) gm-conf %
```



## Approccio Ibrido Multi-Livello

- **Linkage Diretto (Pattern Matching):** Identificazione immediata tramite Regex degli ID ticket nei messaggi di commit (es. commit.getMessage()).
- **Euristica di Recupero (Missing Link Recovery):** Per i commit senza ID, il sistema applica una validazione basata su tre vincoli di integrità:
  - **Vincolo Temporale:** Il commit deve ricadere nell'intervallo (Opening Version, Fix Version) del bug.
  - **Coincidenza di Autore:** Verifica che il commit sia stato effettuato dallo stesso sviluppatore che ha risolto il ticket su Jira.
  - **Consistenza dei File:** Il commit deve aver modificato file già confermati come parte della fix in altri commit associati al ticket.





Per garantire la massima precisione, il sistema non si limita a identificare i file modificati, ma **isola i singoli metodi** difettosi attraverso un'analisi chirurgica del codice sorgente.

**Estrazione dei Diff (JGit):** Per ogni commit di fix, il sistema calcola le differenze rispetto al parent, isolando i blocchi di righe modificati .

**Mappatura dei Confini:** Grazie all'analisi statica, ogni metodo nel dataset è associato a coordinate fisiche precise [*StartLine*, *EndLine*].

**Validazione dell'Intersezione:** Un metodo viene etichettato come *buggy* solo se esiste una sovrapposizione fisica tra le righe variate nel diff e l'intervallo sintattico del metodo stesso.



**Riduzione del Rumore:** Questo approccio permette di scartare le modifiche effettuate nello stesso file ma esterne al metodo (es. refactoring di altri metodi o commenti), assicurando che solo il codice funzionalmente responsabile del bug venga marcato nel dataset.



**Problematica:** L'analisi Method-Level SZZ è un'indagine chirurgica che isola il metodo colpevole nella Fixed Version.

Tuttavia, questo dato descrive la soluzione, ma non l'origine.

## Domanda Chiave:

*"In assenza di Affected Versions su Jira, come identifichiamo tutte le release in cui il metodo era già presente e difettoso?"*

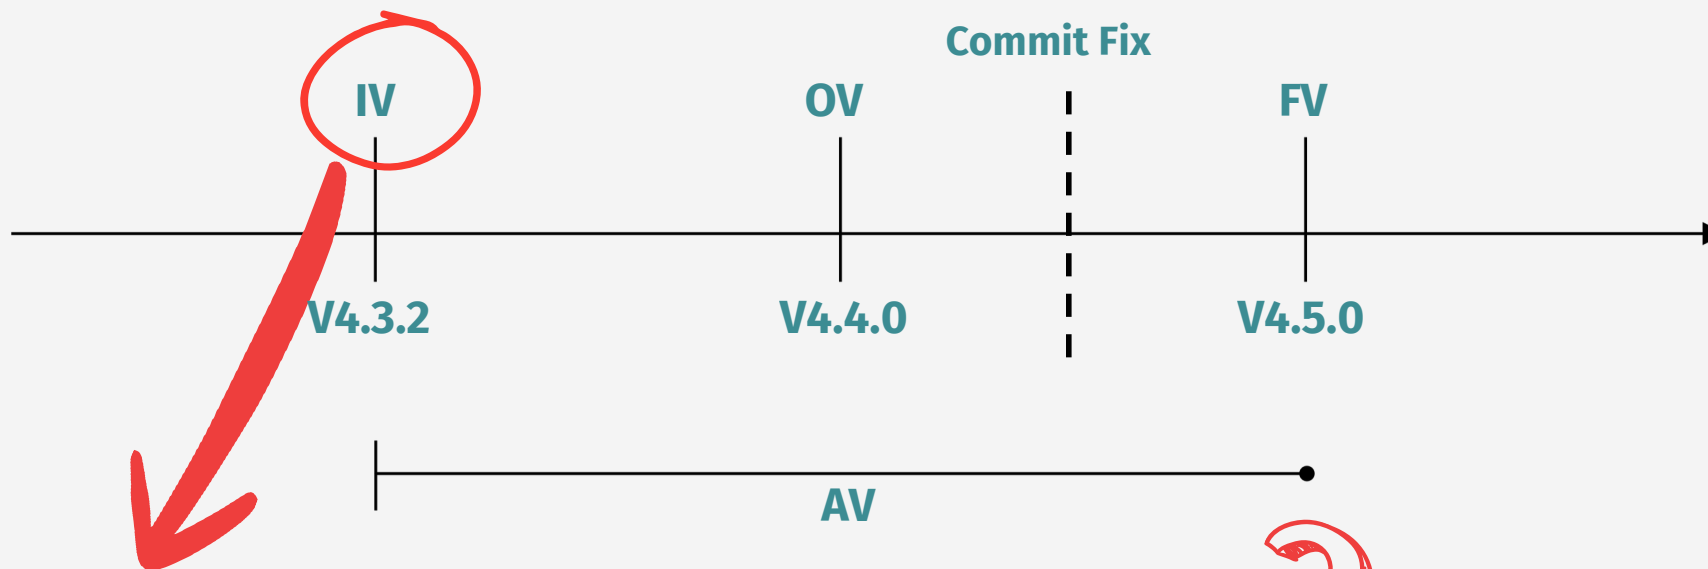




# Dataset ed Estrazione delle Etichette



<<Esisterà un numero *proporzionale* di versioni per trovare il difetto e per risolverlo. >>



$$IV_{index} = FV_{index} - (FV_{index} - OV_{index}) \times P$$



**Filtro Outlier:** Scarto dei ticket aventi  $P > 1.5$

**Cold Start:** Utilizzo di un valore di P globale derivato da benchmark esterni

**Stima Incrementale:** Transizione Automatica a P locale al raggiungimento della soglia di **10 ticket validi**

**Labeling finale:** Propagazione dell'etichetta *buggy* per tutte le istanze dei metodi nell'intervallo [IV, FV)





# Metriche e Definizioni

Metrica	Definizione
MethodHistories	Numero totale di revisioni (commit) subite da un metodo.
DistinctAuthors	Numero di diversi sviluppatori che hanno modificato quel codice.
Churn	Indice di instabilità: quanto spesso il codice viene riscritto o rimosso.
StmtAdded	Quantità totale di istruzioni aggiunte nel ciclo di vita del codice.
StmtDeleted	Quantità totale di istruzioni rimosse nel ciclo di vita del codice.





# Metriche e Definizioni

Metrica	Definizione
StatementCount	Numero complessivo di istruzioni eseguibili presenti.
Number of Smells	Quantità di anomalie nel design che indicano potenziali bug o fragilità.
CyclomaticComplexity	Numero di percorsi logici indipendenti (complessità dei rami if/loop).
CognitiveComplexity	Grado di difficoltà che uno sviluppatore incontra nel capire il flusso del codice.
Nesting Depth	Livello massimo di annidamento di blocchi di codice uno dentro l'altro.
LocalVariableCount	Numero di variabili locali definite.
ReturnTypeComplexity	Grado di complessità del tipo di dato che la funzione restituisce.
LOC	Lines of Code: numero totale di linee che compongono il file.
ParameterCount	Numero di parametri in ingresso a una funzione o metodo.



# Milestone1



	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R
1	Project	Method	ReleaseID	LOC	CyclomaticC	CognitiveCon	Number of S	ParameterCc	NestingDept	StatementCc	LocalVariable	ReturnTypeC	MethodHisto	StmtAdded	StmtDeleted	Churn	DistinctAuth	Bugginess
2	Bookkeeper	../bookkeepe	4.0.0	35	5	5	1	1	2	10	6	1	3	7	3	10	2	Yes
3	Bookkeeper	../bookkeepe	4.0.0	17	2	1	0	1	1	8	2	1	5	35	1	36	1	Yes
4	Bookkeeper	../bookkeepe	4.0.0	20	4	3	0	0	1	10	4	2	6	41	8	49	2	Yes
5	Bookkeeper	../bookkeepe	4.0.0	5	2	1	0	0	1	3	1	1	3	10	1	11	1	Yes
6	Bookkeeper	../bookkeepe	4.0.0	2	1	0	0	2	0	1	0	1	2	4	0	4	1	Yes
7	Bookkeeper	../bookkeepe	4.0.0	9	3	3	1	2	2	3	2	1	3	13	0	13	1	Yes

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R
1	Project	Method	ReleaseID	LOC	CyclomaticC	CognitiveCon	Number of S	ParameterCc	NestingDept	StatementCc	LocalVariable	ReturnTypeC	MethodHisto	StmtAdded	StmtDeleted	Churn	DistinctAuth	Bugginess
2	Openjpa	../openjpa/o	0.9.0	4	2	1	0	2	1	1	0	1	0	0	0	0	0	No
3	Openjpa	../openjpa/o	0.9.0	5	2	1	0	1	1	1	0	1	0	0	0	0	0	No
4	Openjpa	../openjpa/o	0.9.0	5	1	0	1	1	0	1	0	1	0	0	0	0	0	No
5	Openjpa	../openjpa/o	0.9.0	5	1	0	1	1	0	1	0	1	0	0	0	0	0	No
6	Openjpa	../openjpa/o	0.9.0	5	1	0	1	1	0	1	0	1	1	2	0	2	1	No
7	Openjpa	../openjpa/o	0.9.0	5	1	0	1	1	0	1	0	1	0	0	0	0	0	No



Strategia: **10-times 10-cross validation**

Scelta Metodologica: L'analisi focalizzata sul primo **33%** delle release avrebbe reso una suddivisione cronologica troppo frammentata, impedendo al modello di imparare dati significativi.

Feature Selection: Feature Selection di tipo **Filter** basata su **Info Gain** (soglia impostata a **0.1**) per escludere quelle metriche con potere discriminante trascurabile rispetto alla variabile target.









# Protocollo Sperimentale

## NAIVE BAYES



## IBK





## RANDOM FOREST





## Progetto BookKeeper


● Accuracy ● Precision ● Recall ● F1  
● AUC ● Kappa ● NPofB20



**BestClassifier - Caso Studio 1:**  
**BookKeeper**

Classificatore Selezionato: **IBk**  
**(k = 3)**



Performance Distribution across Metrics - BOOKKEEPER





## Progetto OpenJPA


● Accuracy ● Precision ● Recall ● F1  
● AUC ● Kappa ● NPofB20



**BestClassifier - Caso Studio 2:  
OpenJPA**

**Classificatore Selezionato:  
Random Forest**

Performance Distribution across Metrics - OPENJPA






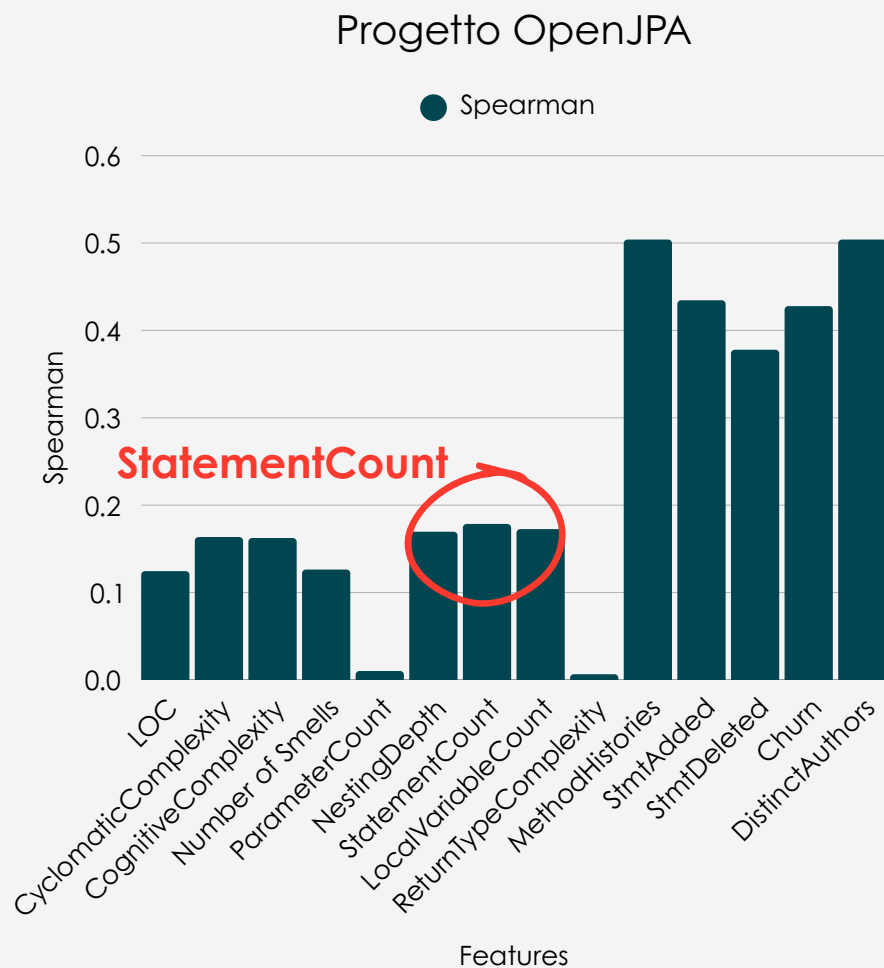
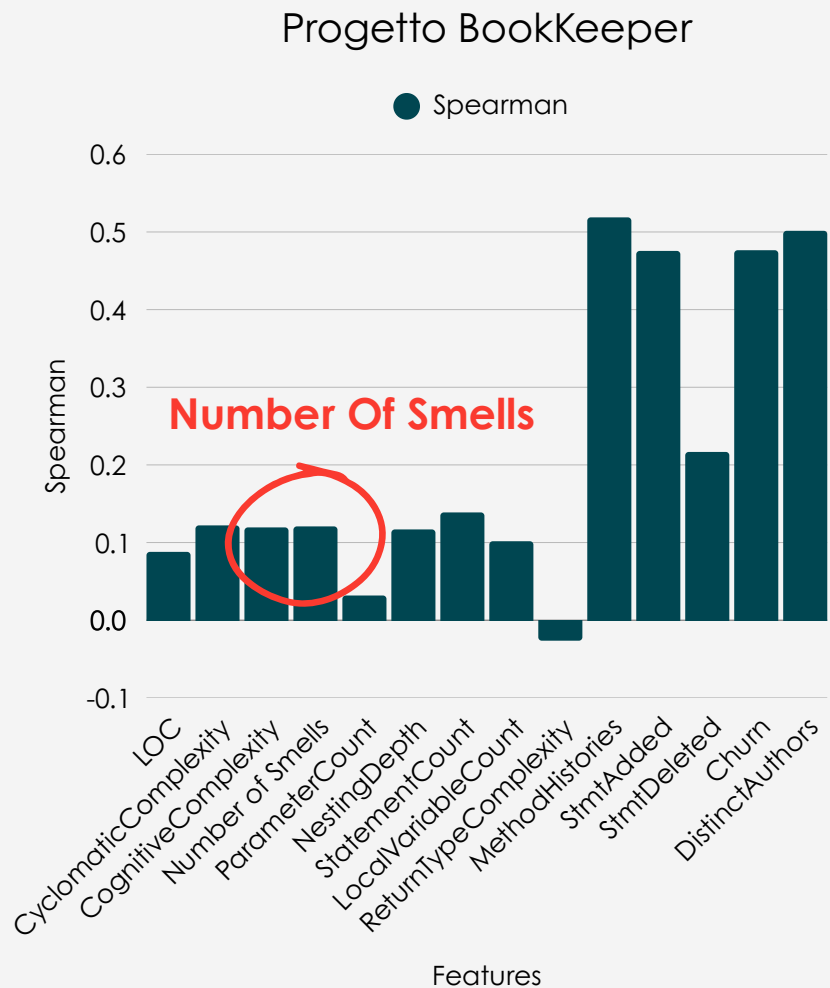
# Risultati



# Selezione dei Metodi Target



**Obiettivo:** identificare quali features hanno il maggiore impatto statistico sulla **bugginess**





# Analisi Critica dei Metodi Target

## Caso Studio 1:

BookKeeper (v4.2.1) Metodo:  
`BenchReadThroughputLatency.main()`

Signature: public static void main(String args)  
throws Exception

Ruolo Operativo: Orchestrazione del benchmark prestazionale, inclusa l'inizializzazione dell'infrastruttura ZooKeeper e la gestione del ciclo di vita dei ledger.

Analisi delle Criticità: Il metodo rappresenta un hotspot qualitativo critico caratterizzato da 8 Code Smell attivi.

## Caso Studio 2:

OpenJPA (v2.0.0) Metodo:  
`FieldMetaData.copy()`

Signature: public void copy(FieldMetaData field)

Ruolo Operativo: Gestione della logica di duplicazione dei metadati di persistenza tra istanze della classe.

Analisi delle Criticità: Nonostante il numero di righe contenuto (55 LOC), il metodo esibisce una densità logica anomala con uno Statement Count di 38.





# Criteri di Identificazione e Strategia di Refactoring

## Problema: 8 Code Smells critici

### Strategia di Refactoring:

1. **Extract Method iterativo:** Scomposizione della logica procedurale del main nei metodi specializzati `getOptions`, `validateArgs` e `setLedgerParams`.
2. **Static Delegation:** Delega della logica dei `Watcher` ai metodi statici `handleZkEvent` e `handleChildrenChanged`.
3. **Specializzazione dell'Exception Handling:** Sostituzione dei `catch` generici con blocchi mirati (`KeeperException`) per garantire resilienza di rete senza oscurare errori critici.
4. **Visibility Refactoring:** Passaggio della visibilità da `private` a `package-private` per eliminare la generazione automatica di metodi sintetici (`AccessorMethodGeneration`).
5. **Type Migration:** Eliminazione dell'overhead degli oggetti wrapper tramite l'uso di primitivi (`parseInt/parseLong`) al posto di `valueOf`.

## Problema: StatementCount elevato


### Strategia di Refactoring:

1. **Extract Method iterativo:** Scomposizione in 3 unità logiche raggruppate per affinità dei dati (`BasicState`, `FetchInfo`, `SequenceInfo`).
2. **Incapsulamento della Logica:** Delegata tutta la logica condizionale (`if/else`) ai sottometodi per "pulire" il flusso del metodo principale.




# Risultati e Validazione

Metodo Pre-Refactoring main()  
BookKeeper



Metodo Pos-Refactoring main()  
BookKeeper




La permanenza di alcuni residui tecnici è frutto di una scelta consapevole: lo smell **Law of Demeter** persiste poiché l'ispezione delle catene di oggetti ZooKeeper è intrinseca al progetto e la sua rimozione tramite wrapper degraderebbe leggibilità e performance; parallelamente, lo smell **SignatureThrows** è stato mantenuto nel metodo main come vincolo architetturale necessario per la corretta propagazione e gestione dei fallimenti critici di sistema."




# Risultati e Validazione

Metodo Pre-Refactoring copy()  
OpenJPA



Metodo Post-Refactoring copy()  
OpenJPA






# Analisi What-IF: metodi buggy evitabili

Case Study	Risultato Post-Refactoring	Stato Finale
BookKeeper	L'obiettivo primario è raggiunto: il cuore del sistema è ora de-classificato come <i>non buggy</i> . Il rischio non è più opaco e distribuito, ma confinato in componenti specifici (startBenchmark, handleChildrenChanged) pronti per testing mirato.	Complessità Isolata
OpenJPA	Abbattimento totale delle probabilità di bugginess su ogni nuovo metodo.	Validazione empirica della transizione a uno stato privo di criticità predetta.

*La **rimozione di una feature actionable** innesca una reazione a catena che abbatte drasticamente tutte le metriche di complessità correlate.*


*Cosa accadrebbe se si avesse la possibilità di azzerare la feature **Number of Smells**?*






# Analisi What-IF: generalizzazione

BookKeeper



OpenJPA



# Analisi What-IF: generalizzazione

Indicatore	Progetto: BookKeeper	Progetto: OpenJPA
Istanze Rimosse	20	262
Fattore Smell (Risk Increment)	25,59%	16,40%
Efficacia (rispetto a B)	0,92%	1,61%
Impatto Totale (rispetto a A)	0,32%	0,60%



# Discussioni e Minacce alla Validità



# Risposte alle domande di ricerca

**RQ1:** IBk eccelle su **dataset ridotti** (**BookKeeper**), mentre **Random Forest** è superiore su **dataset ampi** (**OpenJPA**) per ranking ed efficienza.

**RQ2:** La rimozione dei **Code Smell** riduce il rischio relativo del **25,59%** (**BK**) e del **16,40%** (**OJP**), neutralizzando complessivamente **282 metodi difettosi**.





# Minacce alla Validità !

1. **Interna**: Possibili errori nel tracciamento dei bug o bias manuale durante il refactoring.
2. **Costrutto**: Risultati legati alla precisione dei tool di analisi statica e dei classificatori scelti.
3. **Esterna**: Studio limitato all'ecosistema Apache e al linguaggio Java; la generalizzabilità ad altri contesti va verificata.



# Conclusioni e Sviluppi Futuri



## Conclusioni

**Impatto Qualitativo:** Il refactoring mirato dei Code Smell riduce la probabilità di bug futuri.

**Valore Operativo:** Ottimizzazione delle risorse di testing, concentrando gli interventi sulle componenti a maggior rischio.

## Sviluppi Futuri

**Ottimizzazione:** Esplorazione di tecniche wrapper per affinare la sensibilità dei modelli.

**Automazione:** Integrazione di tool per il suggerimento di refactoring smell-aware in tempo reale.

**Scalabilità:** Replicazione su contesti industriali e analisi longitudinali sulle release future.



GitHub repository per il codice sorgente:  
**[https://github.com/GaiaMeola/Progetto\\_ISW2](https://github.com/GaiaMeola/Progetto_ISW2)**



Dettagli dell'analisi su SonarCloud:  
**[https://sonarcloud.io/project/overview?id=GaiaMeola\\_Progetto\\_ISW2](https://sonarcloud.io/project/overview?id=GaiaMeola_Progetto_ISW2)**

**GRAZIE PER L'ATTENZIONE**